Contagem de frequência de Bytes em diversos tipos de arquivo

CEFET/RJ- Centro Federal de Educação Tecnológica Celso Suckow da Fonseca

Disciplina de Organização e Estrutura de Arquivos

Natália Nunes Vieira

Resumo: Este estudo tem como objetivo realizar uma análise sobre métodos de compressão de arquivos, onde serão analisadas as frequências de bytes ocorrentes em um arquivo antes e depois dos mesmos serem compactados como .zip ou .rar.

Introdução

O trabalho consiste em elaborar um código que seja capaz de contar a frequência de bytes de um arquivo, depois compactar estes arquivos e realizar uma nova contagem de frequência. Identificar o grau de compressão de cada um deles e redigir uma documentação com o que foi analisado. Para isso, o desenvolvimento foi divido em três fases:

Fase 1 (um):

Desenvolver um algoritmo que seja capaz de ler cada Byte de um arquivo e contar a frequência em que eles ocorrem.

O algoritmo precisa:

- Ler uma pasta com diversos tipos de arquivo;
- Ler cada arquivo da pasta individualmente;
- Ler cada Byte do arquivo;
- Identificar qual Byte foi lido;
- Incrementar uma lista com a frequência que cada Byte aparece no arquivo;
- Escrever a lista na tela.

Linguagem: Python

Fase 2 (dois):

Compactar os arquivos utilizando formatos já conhecidos. Será preciso:

- Escolher pelo menos dois formatos de compactação;
- Compactar cada um dos arquivos;
- Identificar o tamanho anterior e posterior à compactação.

Formato dos arquivos: .txt, .pdf, .jpeq, .pnq, .mp3, .mp4.

Formatos para compactação: .rar e .zip

Github: natnvieira7/EstOrgArquivos Página 1

Fase 3 (três):

Comparar a frequência de Bytes dos arquivos antes e depois de serem compactados.

Será preciso:

- Realizar a contagem da frequência de Bytes do arquivo antes da compactação;
- Realizar a contagem da frequência de Bytes do arquivo após a compactação;
- Identificar qual a diferença da contagem entre os dois testes;
- Redigir um documento com o que for identificado entre os arquivos.

Desenvolvimento

Fase 1 (um) - Implementação:

O algoritmo foi desenvolvido na linguagem de programação Python, utilizando a IDE do *Visual Studio Code*. O código encontra-se disponível no *Github* descrito no rodapé do relatório.

```
frequencia.py ×
def contador(caracter, lista):
  pos = ord(caracter)
 lista[pos] = lista[pos] + 1
glob = glob.glob("/Users/Natalia/Documents/projeto/*.*") #alterar o caminho da pasta dependendo do SO
for arq in glob:
  arqui = open(arq, "r", encoding="latin-1") # Mudar o encoding dependendo do SO
  print (arq)
  lista = [0] * 256
  x = arqui.read(1)
  while len(x) != 0:
   contador (x, lista)
   x = arqui.read(1)
  for i in range (0, len(lista)):
            if i<32 or i>126:
                 caracter = "<" + str(i) + ">"
                  caracter=chr(i)
            print (caracter+ " " + str(lista[i]))
```

Figura 1: Contador de frequência de Bytes

Para o código da Figura 1: Contador de frequência de Bytes é importante ressaltar que, para que os testes ocorram com precisão, é necessário alterar o caminho da pasta onde estarão os arquivos para teste, e também verificar o *encoding* utilizado por cada sistema operacional.

Github: natnvieira7/EstOrgArquivos

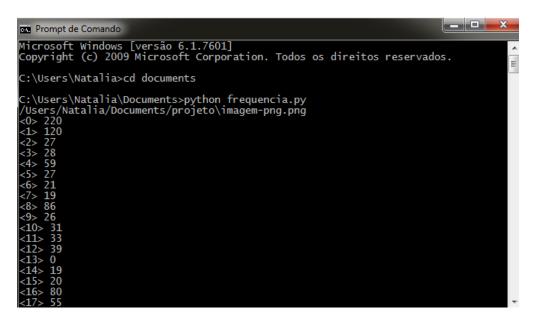


Figura 2: Exemplo de saída no console

Para que fosse gerada uma identificação para cada caractere, utilizamos a tabela ASC II, que pode ser encontrada no GitHub informado no rodapé deste documento.

Fase 2 (dois) - Formatos:

Para a realização dos testes, foram escolhidos os formatos de arquivo .txt, .pdf, .jpeg, .png, .mp3, .mp4. E os formatos de compactação .zip e .rar.



Figura 3: Arquivos nos formatos selecionados

Para cada arquivo foram utilizados os padrões de compactação abaixo descritos na Figura 4: Especificações de compactação .rar e na Figura 5: Especificações de compactação .zip.

Github: natnvieira7/EstOrgArquivos

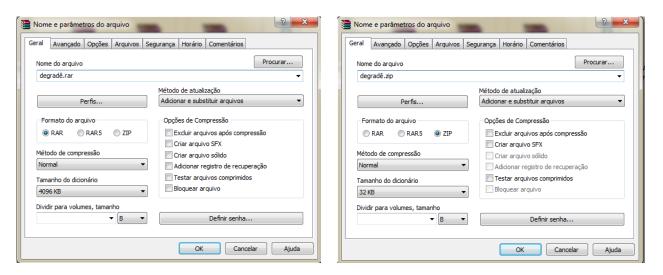


Figura 4: Especificações de compactação .rar

Figura 5: Especificações de compactação .zip

Todos os arquivos foram compactados, conforme a Figura 6: Arquivos originais e compactados.

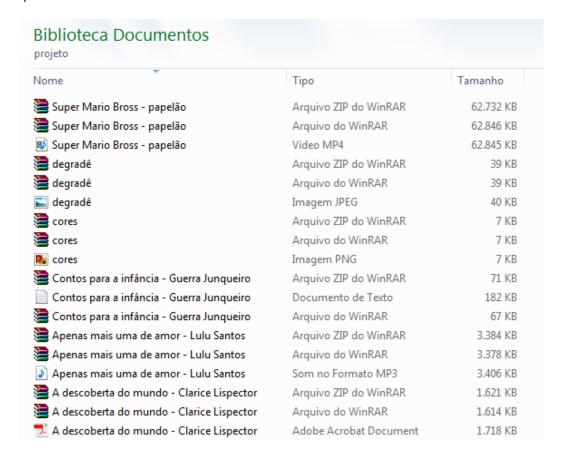


Figura 6: Arquivos originais e compactados

Github: natnvieira7/EstOrgArquivos

Fase 3 (três) - Testes:

Para a realização dos testes foi utilizada uma máquina com a seguinte configuração: processador *Core i5*, 8GB de memória RAM e um SSD de 120 GB. Os arquivos utilizados para execução dos testes encontram-se disponíveis na pasta do drive informada no rodapé deste relatório.

Abaixo, os resultados identificados em cada teste.

✓ <u>.txt:</u>

O arquivo utilizado para testar o formato .txt é o livro Contos para Infância, do autor Guerra Junqueiro e foi obtido através do Projeto Gutemberg.

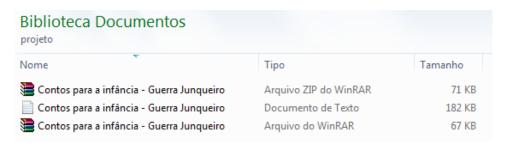


Figura 7: Arquivo .txt original e compactados

Os testes foram realizados para os três formatos de compactação do arquivo, conforme Figura 8: Testes para arquivo .txt original e compactado.

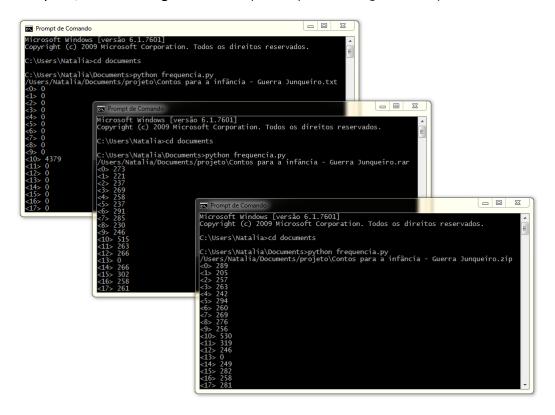


Figura 8: Testes para arquivo .txt original e compactado

Github: natnvieira7/EstOrgArquivos

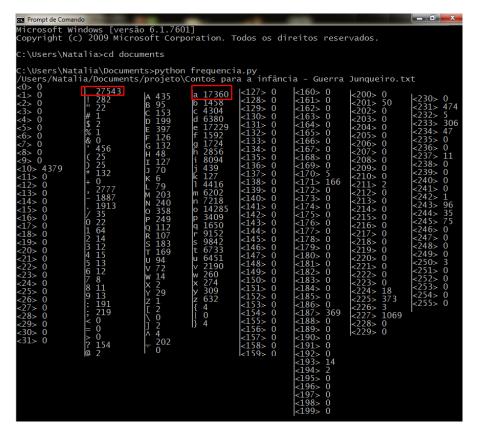


Figura 9: Resultado da contagem de Bytes do arquivo .txt

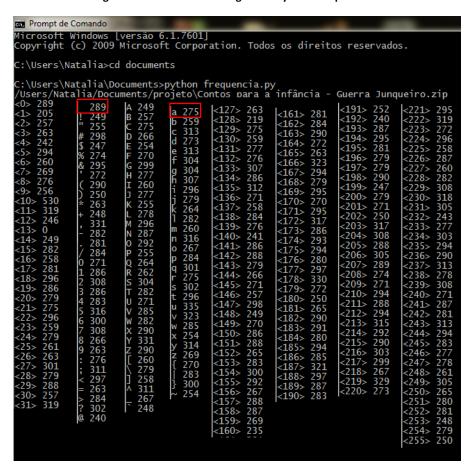


Figura 10: Resultado da contagem de bytes para o arquivo .txt compactado em formato .zip

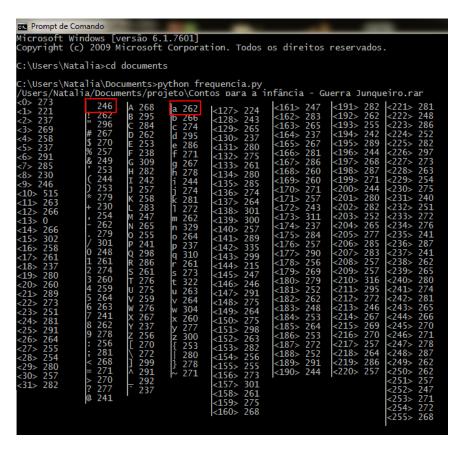


Figura 11: Resultado da contagem de bytes para o arquivo .txt compactado em formato .rar

Na Figura 7: Arquivo .txt original e compactados, podemos perceber a diferença de tamanho para os arquivos compactados, enquanto a compactação em .zip reduziu o arquivo de 182KB para 71KB, a compactação do .rar reduziu o mesmo arquivo para 67KB. Para a análise da frequência de bytes, do arquivo .txt utilizamos, após identificação dos caracteres que apareceram com maior frequência, os caracteres de espaço e 'a' para comparação entre os três tipos de arquivo.

Percebemos que, para o arquivo não compactado, o caractere de *espaço* apareceu 27543 vezes, para 289 vezes no formato *.zip* e 246 vezes no formato *.rar*; para o caractere 'a', a ocorrência identificada no arquivo original foi de 17360 vezes, para 275 vezes no *.zip* e 262 vezes no *.rar*.

	.txt .zip	44 -i	.rar	Frequência de Bytes: Arquivo original/Compactado	
		.zıp		.zip	.rar
espaço	27543	289	246	95,30	111,96
а	17360	275	262	63,13	66,26

Sendo assim, é possível identificar que, após a compactação do arquivo, tanto pela frequência de bytes, quanto pelo tamanho dos arquivos, para um formato .txt, o formato de compactação .rar compacta melhor que o .zip.

Github: natnvieira7/EstOrgArquivos

✓ .pdf:

Para os testes com arquivo pdf foi selecionado o livro *A Descoberta do Mundo*, de autora Clarice Lispector. O arquivo foi disponibilizado pela equipe do *LeLivros*, para uso parcial em pesquisas e estudos acadêmicos.

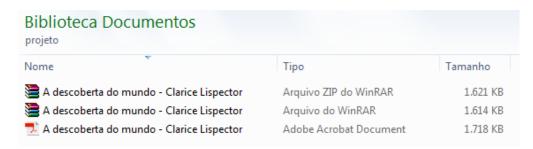


Figura 12: Arquivo .pdf original e compactados

Os testes foram realizados para os três formatos do arquivo, conforme Figura 13: Compactação de arquivo .pdf.

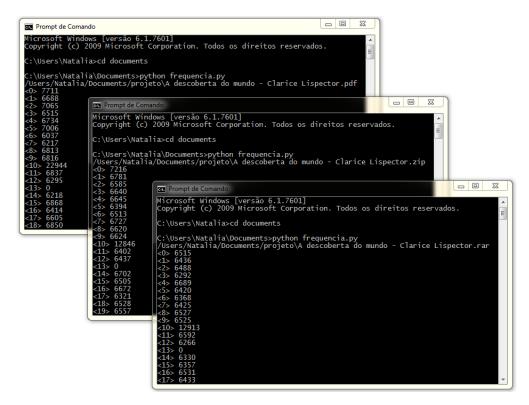


Figura 13: Compactação de arquivo .pdf

Github: natnvieira7/EstOrgArquivos

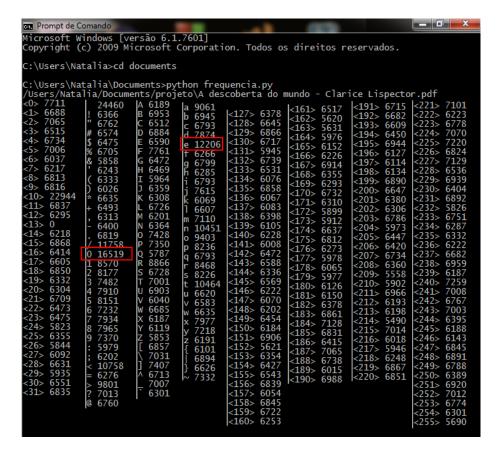


Figura 14: Resultado da contagem de bytes para o arquivo .pdf

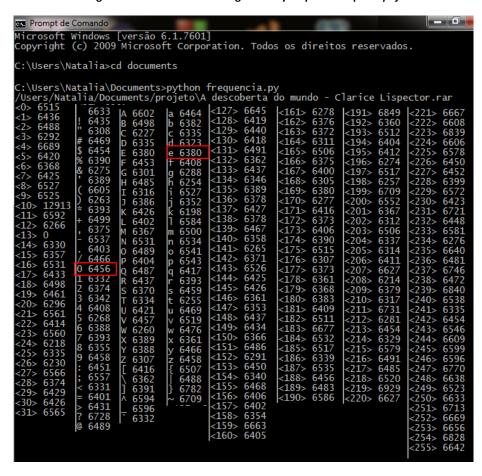


Figura 15: Resultado da contagem de bytes para o arquivo .pdf compactado em formato .rar

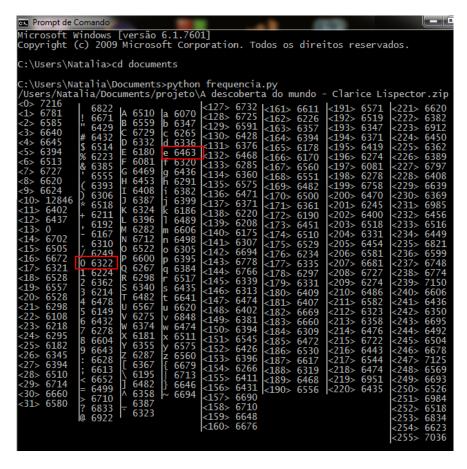


Figura 16: Resultado da contagem de bytes para o arquivo .pdf compactado em formato .zip

A Figura 12: Arquivo .pdf original e compactados, nos permite identificar a redução de tamanho para os arquivos .pdf, compactados em .zip e .rar. Ao comparar os valores que em .pdf foram de 1718 KB, em .zip teve uma redução para 1621KB e 1614KB em .rar.

Para analisar a frequência de Bytes, os caracteres escolhidos foram o numeral '0' e a letra 'e', onde o '0' aparecia 16519 vezes no arquivo .pdf e passou a aparecer 6322 vezes no .zip e 6456 no .rar; e a letra 'e' aparecia 12206 vezes no arquivo .pdf e reduziu para 6463 aparecimentos no .zip e 6380 no .rar.

	.pdf	.zip	.rar	Frequência de Bytes: Arquivo original/Compactado	
				.zip	.rar
0	16519	6322	6456	2,61	2,56
е	12206	6463	6380	1,89	1,91

Após análise do tamanho dos arquivos e da frequência dos bytes '0' e 'e' pudemos perceber que, apesar do arquivo original ter sido compacto, o formato de arquivo .pdf não teve uma redução significativa em nenhum dos dois formatos.

Github: natnvieira7/EstOrgArquivos



A imagem abaixo utilizada para os testes em .jpg foi obtida através do Google Imagens e está disponível para download no Pinterest.

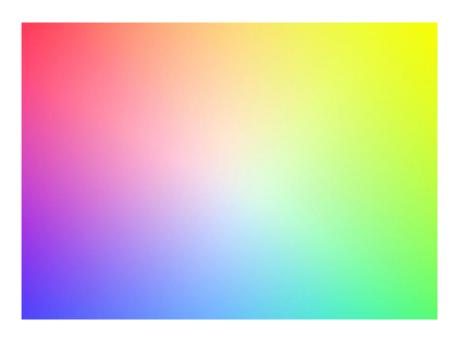


Figura 17: Imagem utilizada para o teste de contagem de frequência de Byte no formato .jpg

Github: natnvieira7/EstOrgArquivos

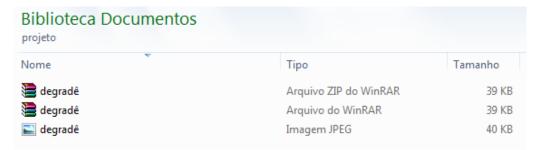


Figura 18: Arquivo .jpg original e compactados

Os testes foram realizados para os três formatos do arquivo, conforme Figura 19: Compactação de arquivo .jpg.

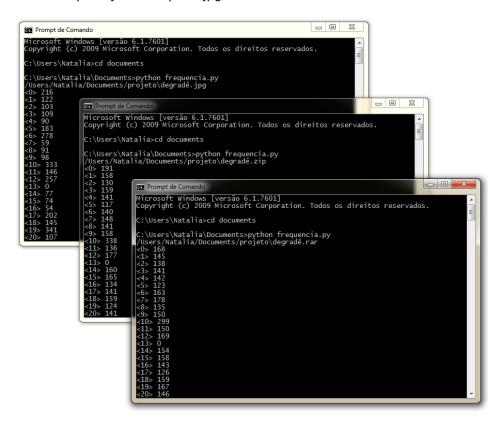


Figura 19: Compactação de arquivo .jpg

Github: natnvieira7/EstOrgArquivos

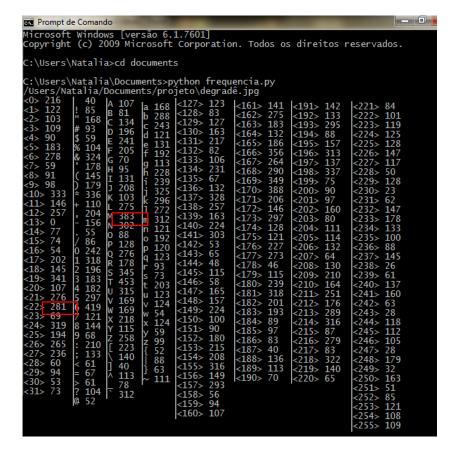


Figura 20: Resultado da contagem de bytes para o arquivo .jpg

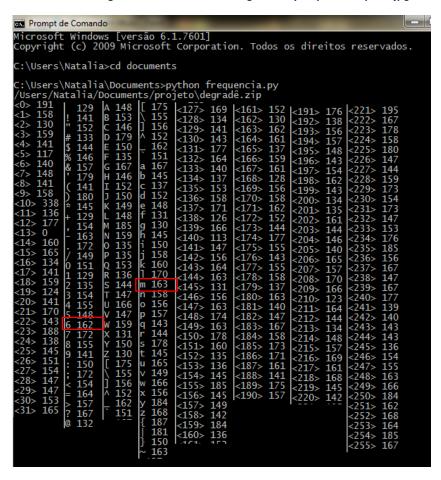


Figura 21: Resultado da contagem de bytes para o arquivo .jpg compactado em formato .zip

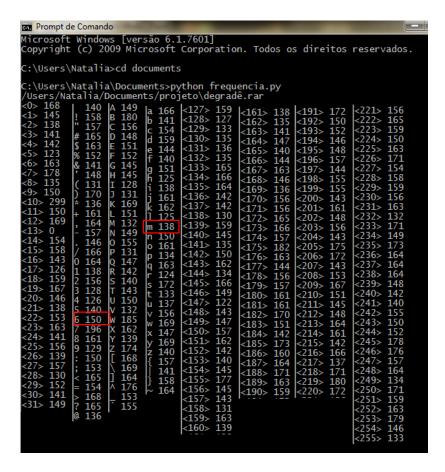


Figura 22: Resultado da contagem de bytes para o arquivo .jpg compactado em formato .rar

A Figura 18: Arquivo .jpg original e compactados nos mostra a redução de tamanho entre os formatos .jpeg, .zip e .rar, e, através dela, podemos concluir que a compactação identificada foi mínima, considerando que um arquivo que antes tinha 40KB passou a ter 39KB em ambos os formatos de compactação.

Na Figura 20: Resultado da contagem de bytes para o arquivo .jpg, Figura 21: Resultado da contagem de bytes para o arquivo .jpg compactado em formato .zip e Figura 22: Resultado da contagem de bytes para o arquivo .jpg compactado em formato .rar, foram destacados os caracteres encontrados em maior número no formato .jpg: '6' e 'm'. Para o formato .jpg, eles apareceram 419 vezes e 312 vezes, respectivamente. Para o formato .zip, os caracteres passaram a aparecer 162 e 163 vezes, respectivamente. E, para o formato .rar, a aparição dos caracteres ocorreu em 150 e 138 vezes, respectivamente.

	.jpg .zip	~	202	Frequência de Bytes: Arquivo original/Compactado	
		.rar	.zip	.rar	
6	419	162	150	2,58	2,79
m	312	163	138	1,91	2,26

Com base nos valores identificados na Figura 18: Arquivo .jpg original e compactados e na Figura 20: Resultado da contagem de bytes para o arquivo .jpg, Figura 21: Resultado da contagem de bytes para o arquivo .jpg compactado em formato .zip e Figura 22:

Github: natnvieira7/EstOrgArquivos

Resultado da contagem de bytes para o arquivo .jpg compactado em formato .rar, podemos concluir que, como o .jpg é um formato de fácil compactação por ser gerado em blocos, a imagem utilizada no teste já possuía um alto nível de compactação, considerando que a diferença entre os tamanhos do arquivo original e dos compactados foi de apenas 1KB e a redução das frequências é inferior a 3 vezes menor.

✓ .png:

A imagem abaixo foi utilizada para os testes, foi encontrada através do *Google Imagens* e está disponível no *Pinterest*.



Biblioteca Documentos projeto		
Nome	Tipo	Tamanho
cores	Arquivo ZIP do WinRAR	7 KB
cores	Arquivo do WinRAR	7 KB
№ cores	Imagem PNG	7 KB

Figura 23: Arquivo .png original e compactados

Os testes foram realizados para os três formatos do arquivo, conforme Figura 24: Compactação de arquivo .png.

Github: natnvieira7/EstOrgArquivos

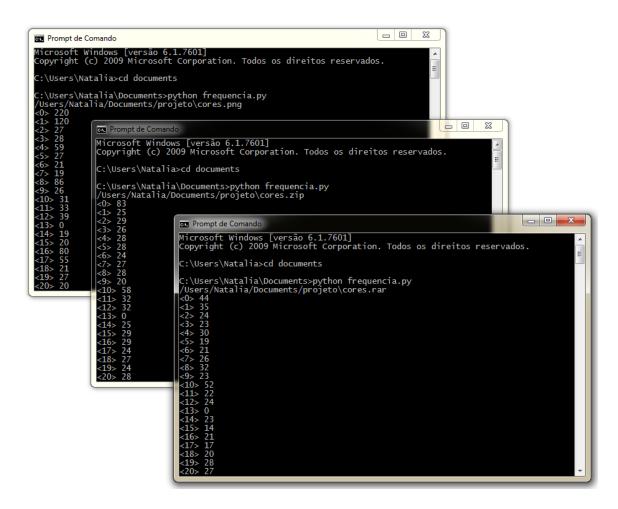


Figura 24: Compactação de arquivo .png

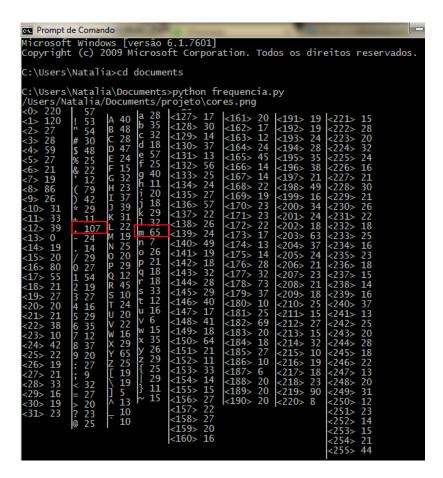


Figura 25: Resultado da contagem de bytes para o arquivo .png

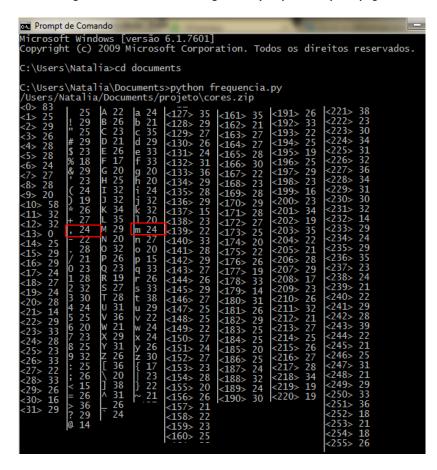


Figura 26: Resultado da contagem de bytes para o arquivo .png compactado em formato .zip

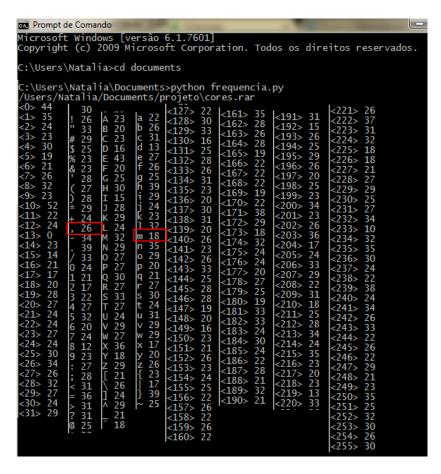


Figura 27: Resultado da contagem de bytes para o arquivo .png compactado em formato .rar

Na Figura 23: Arquivo .png original e compactados é possível perceber que quando o arquivo .png foi compactado não houve redução de tamanho e o arquivo que possuía 7KB se manteve com os 7KB no formato .zip e no formato .rar, isto não necessariamente se deve ao formato possuir baixo poder de compressão e sim aos pixels da imagem, que, por ser muito colorida, minimiza os bytes que podem ser suprimidos.

Na Figura 25: Resultado da contagem de bytes para o arquivo .png, Figura 26: Resultado da contagem de bytes para o arquivo .png compactado em formato .zip e Figura 27: Resultado da contagem de bytes para o arquivo .png compactado em formato .rar escolhemos os caracteres ',' e 'm', que foram identificados com maior frequência no formato .png, para realizarmos a análise. No formato .png a ',' apareceu 107 vezes, para 24 no .zip e 26 no .rar; já o caractere 'm', a frequência encontrada foi de 65 aparições no arquivo .png para 24 no .zip e 18 no .rar.

	.png .z	.zip	.rar	Frequência de Bytes: Arquivo original/Compactado	
		.21ρ		.zip	.rar
,	107	24	26	4,46	4,11
т	65	24	18	2,7	3,61

De acordo com o que foi identificado para o arquivo png, podemos concluir que, apesar da frequência de Bytes ter diminuído em média 4 vezes nos caracteres analisados

Github: natnvieira7/EstOrgArquivos

para ambos os formatos, o tamanho dos arquivos se manteve constante, sendo assim, ainda que a compressão não tenha sido capaz de reduzir o tamanho da imagem a freguência de Bytes de alterou.

✓ .mp3:

O arquivo .mp3 utilizado para a análise da contagem de frequência foi a música Apenas mais uma de amor, do Lulu Santos.

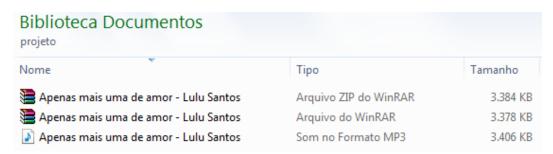


Figura 28: Arquivo .mp3 original e compactados

Os testes foram realizados para os três formatos do arquivo, conforme Figura 29: Compactação de arquivo .mp3.

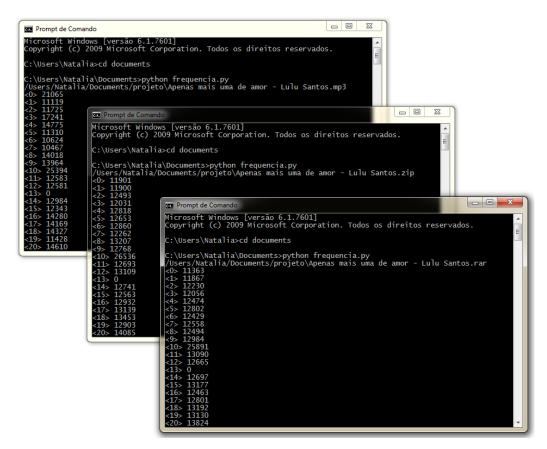


Figura 29: Compactação de arquivo .mp3

Github: natnvieira7/EstOrgArquivos

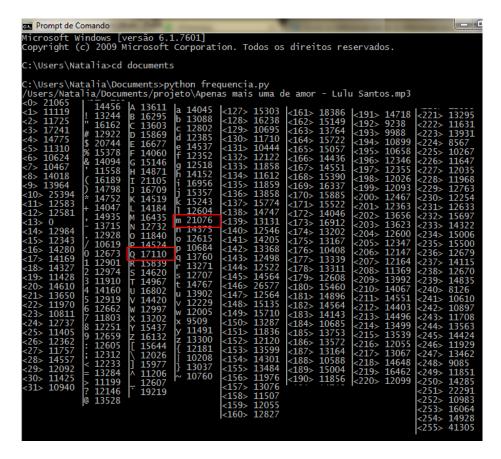


Figura 30: Resultado da contagem de bytes para o arquivo .mp3

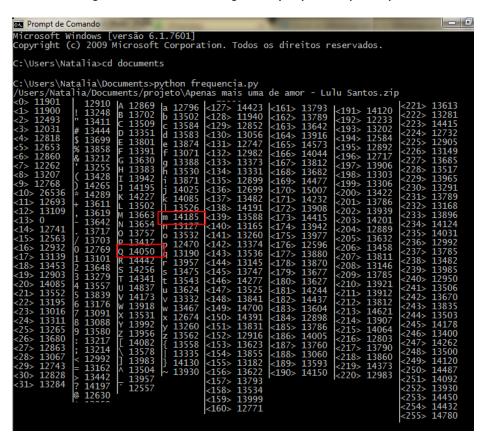


Figura 31: Resultado da contagem de bytes para o arquivo .mp3 compactado em formato .zip

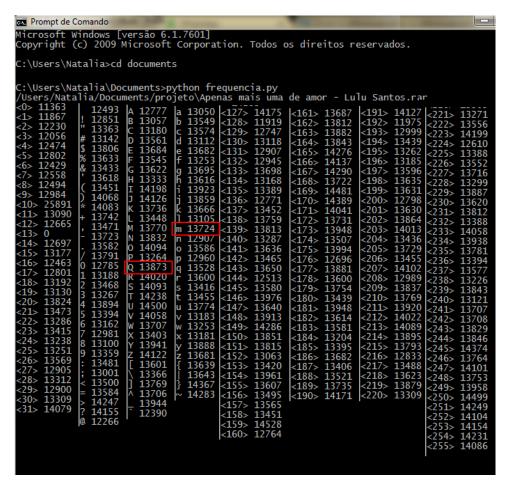


Figura 32: Resultado da contagem de bytes para o arquivo .mp3 compactado em formato .rar

Para a compressão de um arquivo .mp3, identificamos através da Figura 28: Arquivo .mp3 original e compactados, que apesar do formato já ser compactado, houve compressão e diminuição do tamanho dos arquivos, que originalmente tinha 3406KB e passaram a ter 3384KB no formato .zip e 3378KB no formato .rar. Ainda assim, o valor reduzido é quase insignificante para o tamanho total do arquivo.

Nos testes de frequência de bytes, identificados na Figura 30: Resultado da contagem de bytes para o arquivo .mp3, Figura 31: Resultado da contagem de bytes para o arquivo .mp3 compactado em formato .zip e Figura 32: Resultado da contagem de bytes para o arquivo .mp3 compactado em formato .rar, foram escolhidos os caracteres 'Q' e 'm', que tiveram uma redução significativa se comparada à redução de tamanho total dos arquivos. Para o caractere 'Q', que aparecia 17110 vezes no arquivo original, passou a aparecer 14050 vezes no arquivo .zip e 13873 vezes no .rar. Para o caractere 'm', a incidência de 21076 vezes no arquivo principal caiu para 14185 vezes no .zip e 13724 vezes no .rar.

	.png .zip	zio.	.rar	Frequência de Bytes: Arquivo original/Compactado	
		.21ρ		.zip	.rar
Q	17110	14050	13873	1,22	1,23

Github: natnvieira7/EstOrgArquivos

m	21076	14185	13724	1,48	1,53
				-	

Na tabela acima é possível perceber que, apesar do arquivo ter sido comprimido, a diferença de tamanho é extremamente insignificante, considerando que os caracteres analisados não atingiram redução de nem 50% da frequência.

✓ <u>.mp4:</u>

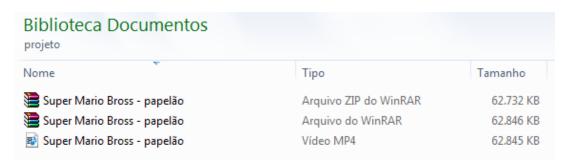


Figura 33: Arquivo .mp4 original e compactados

Os testes foram realizados para os três formatos do arquivo, conforme Figura 34: Compactação de arquivo .mp4.

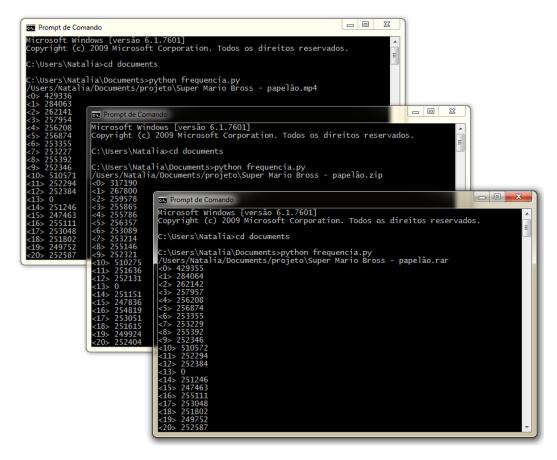


Figura 34: Compactação de arquivo .mp4

Github: natnvieira7/EstOrgArquivos

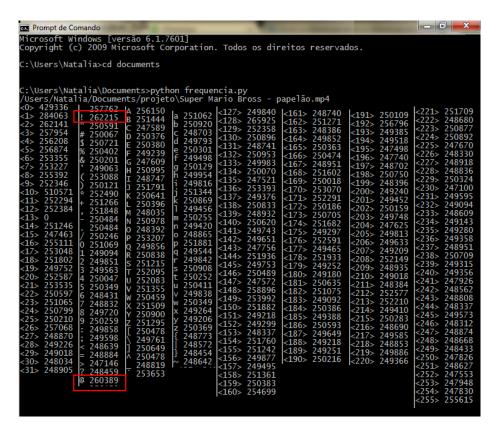


Figura 35: Resultado da contagem de bytes para o arquivo .mp4

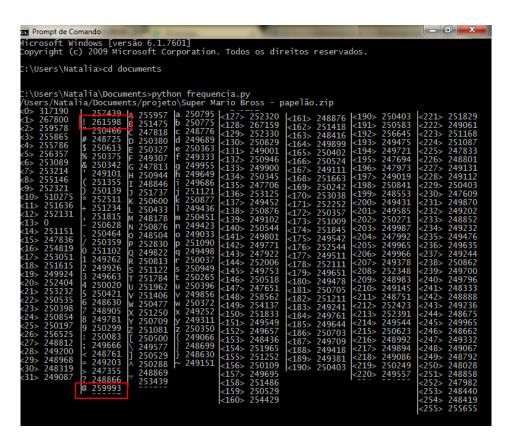


Figura 36: Resultado da contagem de bytes para o arquivo .mp4 compactado em formato .zip

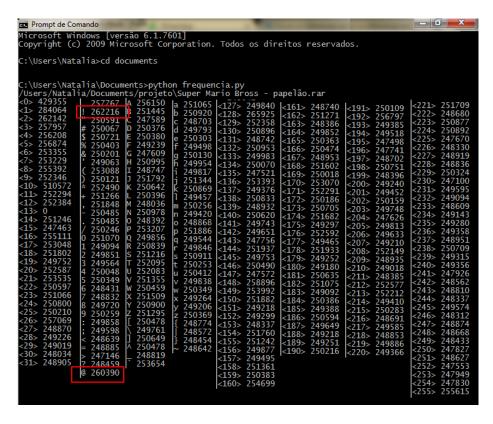


Figura 37: Resultado da contagem de bytes para o arquivo .mp4 compactado em formato .rar

Com o auxílio da Figura 33: Arquivo .mp4 original e compactados é possível perceber que, apesar da compressão do arquivo .mp4 para o formato .zip ter gerado uma compressão mínima, a compressão do mesmo para o formato .rar, além de não ter reduzido seu tamanho, o tornou 1KB maior do que no formato original.

Na análise da frequência de bytes, foram utilizados os caracteres '!' e '@', que, como podemos ver na Figura 35: Resultado da contagem de bytes para o arquivo .mp4, Figura 36: Resultado da contagem de bytes para o arquivo .mp4 compactado em formato .zip e Figura 37: Resultado da contagem de bytes para o arquivo .mp4 compactado em formato .rar, possuíam 262215 e 260389 aparições no arquivo principal, respectivamente; estes valores foram reduzidos para 261598 e 259993 aparições para os caracteres no arquivo .zip e sofreram um aumento de um byte para cada caractere, que passaram a ter frequência de 262216 e 260390 vezes, respectivamente no arquivo .rar.

	.png .zip	-i-	.rar	Frequência de Bytes: Arquivo original/Compactado	
		.21ρ		.zip	.rar
!	262215	261598	262216	1	0,99
@	260389	259993	260390	1	0,99

Com o auxílio da tabela acima, podemos verificar que, pelo fato de o formato de arquivo .mp4 ser naturalmente comprimido, as diferenças geradas na frequência dos

Github: natnvieira7/EstOrgArquivos

bytes em cada arquivo se torna insignificante tanto para a diminuição, quanto para o aumento de frequência de cada caractere.

Conclusão

Após análise da frequência dos bytes nos formatos de arquivo .txt, .pdf, .jpg, .png, .mp3, .mp4 e suas compressões para os formatos .zip e .rar, pudemos perceber que nem todo formato de arquivo é suficientemente compactável, e que nem sempre a frequência dos bytes se torna menor em um arquivo após sua compactação. Identificamos também que, para a maioria dos formatos, nos testes realizados, a compactação para .rar foi superior, tornando-a melhor no quesito compressão, porém, para o único formato (.mp4) onde o .rar não teve maior índice de compressão, ele também tornou o arquivo maior que o formato original.

Também foi identificada uma semelhança para as compactações de imagens, onde em ambos os formatos (.*jpg* e .*png*) as compactações tiveram o mesmo tamanho (em .*jpg* a redução de 1KB e em .*png* sem reduções).

Considerando que só foram realizados testes com um arquivo de cada formato, para que a pesquisa tenha maior garantia é recomendado realizar testes com mais de um arquivo do mesmo formato, e também, como futuros trabalhos, seria interessante o estudo sobre outros formatos menos utilizados, tanto para arquivos quanto para formatos de compactação, ou até mesmo a comparação entre arquivos de mesmo tipo, seja ele texto, imagem, áudio ou vídeo.

Github: natnvieira7/EstOrgArquivos Página 25